



强化学习驱动的大语言模型推理能力提升

从策略梯度到 GRPO：推理能力优化的技术演进路径

李瀚轩，梅敏炫，王垠凯，郑涵文

计算机科学思想史小组报告

2025 年 5 月 28 日

Overview

Overview

Background

Method

Future Development Prospects

References



Background

- 传统 LLM 的局限
 - 依赖监督微调 (SFT), 泛化能力弱, 难以处理复杂多步推理.
 - 自回归生成易积累错误, 缺乏全局优化目标.
- RL 的优势
 - RL 的目的: 找到一个 policy, 这个 policy 根据当前观测到的环境状态和奖励反馈, 来选择最佳的动作.
 - 应用到 NLP 中: 将推理步骤视为动作序列 (生成 token/子结论), 状态 (当前文本), 奖励 (最终正确性 + 过程约束)
 - 探索高质量推理路径, 超越监督数据局限.

RL Basics

Basic Concepts and Notations

- 某时间步的状态 (State), agent 采取的动作 (Action): s_t, a_t
- 策略 (Policy) $a_t \sim \pi_\theta(\cdot|s_t)$: 在 s_t 下, agent 可能执行的动作服从概率分布 π_θ
- 奖励 (Reward): 单步奖励 r_t , T 步累计折扣奖励 $R(\tau) = \sum_{t=0}^{\infty} \gamma^t r_t$
- 状态价值函数: 在状态 s 下的期望回报 $V(s) = \mathbb{E}_{\tau \sim \pi}[R(\tau)|s_0 = s]$
- 动作价值函数: 状态 s 下执行动作 a 的期望回报 $Q(s, a) = \mathbb{E}_{\tau \sim \pi}[R(\tau)|s_0 = s, a_0 = a]$
- 优势函数: $A(s, a) = Q(s, a) - V(s)$

Policy Gradient

- 优化目标是最大化期望奖励: $\nabla J(\pi_\theta) = \mathbb{E}_{\tau \sim \pi_\theta}[R(\tau) \cdot \sum_{t=0}^{T-1} \nabla \log \pi_\theta(a_t|s_t)]$
- 采样足够多的轨迹来估计这个期望:

$$J(\pi_\theta) = \mathbb{E}_{\tau \sim \pi_\theta}[R(\tau) \cdot \sum_{t=0}^{T-1} \log \pi_\theta(a_t|s_t)] \approx \frac{1}{N} \sum_{n=0}^{N-1} \sum_{t=0}^{T-1} \log \pi_\theta(a_t|s_t)$$

PPO: Proximal Policy Optimization

- PPO 的改进

- Policy Gradient 的局限: 高方差导致训练不稳定, 需要大量样本
- PPO 的解决方法: 重要性采样 + 更新幅度约束

PPO-Clip loss function

$$L^{CLIP}(\theta) = \mathbb{E}_t[\min(r_t(\theta)A_\phi^{GAE}(s_t, a_t), \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon)A_\phi^{GAE}(s_t, a_t))]$$

PPO-Penalty loss function

$$\arg \max_{\pi_\theta} \mathcal{J}_{\pi_\theta} = \mathbb{E}[r_t(\theta)A_\phi^{GAE}(s_t, a_t) - \beta \text{KL}(\pi_{\theta_{old}}(\cdot|s_t)||\pi_\theta(\cdot|s_t))]$$

- 在 RLHF 中的应用

- RLHF: 监督微调 (SFT) $\rightarrow$ 奖励模型训练 $\rightarrow$ PPO 强化学习
- 优化两个网络: Actor (policy), Critic (value)

GRPO: Group Relative Policy Optimization

- PPO 的局限: 需要一个大小与 Actor 模型相当的 Critic 模型来预测 Value.
- GRPO 的解决方法: 去掉 Critic Model 并重新定义优势函数

GRPO loss function


$$\mathcal{J}_{GRPO}(\theta) = \mathbb{E}[q \sim P(Q), \{o_i\}_{i=1}^G \sim \pi_{\theta_{old}}(O|q)]$$

$$\frac{1}{G} \sum_{i=1}^G \frac{1}{|o_i|} \sum_{t=1}^{|o_i|} \left\{ \min \left[r_t(\theta) \hat{A}_{i,t}, \text{clip} \left(r_t(\theta), 1 - \epsilon, 1 + \epsilon \right) \hat{A}_{i,t} \right] - \beta \mathbb{D}_{KL} [\pi_{\theta} || \pi_{ref}] \right\},$$

where $\hat{A}_{i,t} = \frac{r_i - \text{mean}(\mathbf{r})}{\text{std}(\mathbf{r})}, \quad r_t(\theta) = \frac{\pi_{\theta}(o_{i,t}|q, o_{i,<t})}{\pi_{\theta_{old}}(o_{i,t}|q, o_{i,<t})}$

(1)

GRPO: Group Relative Policy Optimization



DAPO: Decouple Clip and Dynamic Sampling Policy Optimization

- GRPO 的局限: 训练时间长, 上限不高 (探索策略有限).
- DAPO 做出的改动:
 - 移除 KL 散度 penalty: 使用 long-CoT 训练模型, 本身就会与初始分布产生较大偏移.
 - 调高 ϵ (Clip Higher): 促进更多样化样本的生成.
 - Dynamic Sampling: 减少无效训练 (对准确率等于 1 的 prompt 进行过滤)
 - Token-level reward: 改变 loss normalization 的范围

DAPO loss function

$$\begin{aligned}
 \mathcal{J}_{\text{DAPO}}(\theta) = & \mathbb{E}_{(q,a) \sim \mathcal{D}, \{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(\cdot|q)} \\
 & \left[\frac{1}{\sum_{i=1}^G |o_i|} \sum_{i=1}^G \sum_{t=1}^{|o_i|} \min \left(r_{i,t}(\theta) \hat{A}_{i,t}, \text{clip} \left(r_{i,t}(\theta), 1 - \epsilon_{\text{low}}, 1 + \epsilon_{\text{high}} \right) \hat{A}_{i,t} \right) \right] \quad (2) \\
 \text{s.t. } & 0 < \left| \{o_i \mid \text{is_equivalent}(a, o_i)\} \right| < G.
 \end{aligned}$$

RL for Reasoning in LLMs with One Training Example

- One-Shot-RLVR: 从数据选择的角度来进行优化
 - 在多大程度上减少训练数据集，同时仍能保持与使用完整数据集相当的性能？
- 仅需一个训练样本即可大幅提升 LLM 数学推理能力
 - 在数学推理 benchmark 上表现匹配 1.2k 样本训练效果
 - 饱和后泛化 (Post-Saturation Generalization): 训练集准确率早饱和，但测试集性能持续提升
 - 跨领域泛化: 单几何样本训练提升代数/数论表现

未来发展展望

- Algorithm Level
 - 针对 Advantage/Loss Function 提出优化 (e.g. 将逻辑规则, 符号系统融入函数表达式)
 - 多模态推理扩展: RL 增强跨模态推理 (视觉模型, 语言模型)
- System Level
 - 在 VeRL 的基础上进一步优化训练过程, 设计更好的分布式训练算法与系统
- Theory Level
 - RL 在提升 LLM 推理能力中有很多有意思的现象, 能否使用数学语言来描述?
 - ML theory: 揭开深度神经网络的黑盒, formulatively rather than empirically.
-

References

- Proximal Policy Optimization Algorithms
- Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning
- Training language models to follow instructions with human feedback
- DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models
- DAPO: An Open-Source LLM Reinforcement Learning System at Scale
- Reinforcement Learning for Reasoning in Large Language Models with One Training Example