



浙江大學
ZHEJIANG UNIVERSITY

计算机科学思想史课程报告

生成模型量化调研

姓名 李瀚轩

学号 3220106039

院所 计算机科学与技术学院

2025 年 6 月 7 日

目录

1	引言	3
2	生成模型架构演进与量化挑战	3
2.1	从 U-Net 到 Diffusion Transformers 的架构变革	3
2.2	架构变化对量化技术的影响	4
2.3	视频生成的额外复杂性	4
3	量化技术基础理论与方法	5
3.1	量化数学基础	5
3.2	传统量化方法的局限性	5
3.3	生成模型量化的核心挑战	5
4	现有量化技术深入分析	6
4.1	通用量化方法的发展	6
4.1.1	SmoothQuant: 平衡权重与激活量化	6
4.1.2	QuaRot: 基于旋转的量化优化	6
4.2	DiT 专用量化技术详解	8
4.2.1	PTQ4DiT: 开创性的 DiT 量化方法	8
4.2.2	SVDQuant: 极低比特量化的突破	9
4.3	视频生成量化的专门技术	10
4.3.1	ViDiT-Q: 统一的图像视频量化框架	10
4.3.2	DVD-Quant: 免标定数据的视频量化	11
5	技术总结与发展	13

1 引言

近年来，基于扩散模型（Diffusion Models）的生成技术在计算机视觉领域取得了革命性突破，从早期的 DDPM 到当前的 Stable Diffusion、DALL-E 3，再到最新发布的 Sora [1]，生成模型的能力不断突破人类想象的边界。这些模型不仅能够生成高质量的图像和视频内容，还具备了理解复杂文本描述、控制生成风格、保持时间一致性等高级能力，为数字内容创作、影视制作、游戏开发等众多领域带来了前所未有的变革机遇。

然而，伴随着生成质量的显著提升，模型的规模和复杂度也呈现出指数级增长趋势。以视频生成为例，OpenAI 的 Sora 模型据估计拥有数十亿参数，而最新开源的 HunyuanVideo 模型达到了 130 亿参数规模 [2]。这种参数规模的急剧扩张带来了严峻的部署挑战：首先是存储成本的飙升，一个 130 亿参数的模型在 FP16 精度下需要约 26GB 的存储空间；其次是计算开销的激增，生成一个 512×512 分辨率的 16 帧视频在 NVIDIA RTX 4090 上需要 50 秒以上的时间；最后是内存需求的巨大压力，完整加载这些模型需要高端 GPU 的全部显存，这极大地限制了模型的实际应用范围。

量化技术作为一种成熟的模型压缩方法，通过将模型的权重和激活值从高精度浮点数转换为低比特整数表示，能够在保持合理性能的前提下显著减少模型的存储空间和计算开销。在传统的计算机视觉任务中，量化技术已经得到了广泛应用并取得了良好效果。然而，生成模型的量化面临着独特的挑战：生成任务对细节保真度要求极高，微小的量化误差可能导致明显的视觉伪影；扩散过程的多步骤特性使得误差在时间维度上累积；不同于分类任务的单一输出，生成模型需要保持输出分布的复杂性和多样性。

本文旨在系统梳理生成模型量化技术的发展脉络，深入分析现有方法的技术原理与局限性，并展望该领域的未来发展方向。

2 生成模型架构演进与量化挑战

2.1 从 U-Net 到 Diffusion Transformers 的架构变革

早期的扩散模型主要采用基于卷积神经网络的 U-Net 架构，这种设计源于图像分割任务的成功经验。U-Net 通过编码器-解码器结构处理图像的多尺度特征，利用跳跃连接保持细节信息，在图像生成任务中展现出良好的性能。

然而，U-Net 架构存在固有的局限性。首先，其归纳偏置限制了模型的可扩展性，难以充分利用大规模数据和计算资源；其次，卷积操作的局部性特征使得模型在处理长距离依赖关系时效果有限；最后，复杂的多尺度结构增加了网络设计的复杂度，不利于模型的标准化和优化。

Diffusion Transformers (DiT) 的提出标志着生成模型架构的重大突破 [3]。DiT 将传统的 U-Net backbone 替换为标准的 Transformer 架构，通过以下关键设计实现了性能的显著提升：

-
1. **Patch-based 处理**: 将输入图像分割为固定大小的 patch 序列, 每个 patch 通过线性投影转换为 token 表示。
 2. **位置编码**: 采用可学习的位置编码表示 patch 在图像中的空间位置信息。
 3. **条件注入**: 通过 adaptive layer normalization (adaLN) 将时间步骤和文本条件信息注入到每个 Transformer 层。并且通过 3D attention 机制更好地捕捉文本和图像之间的关系, 引导生成内容与文本的更好对齐。
 4. **标准化架构**: 采用标准的 multi-head self-attention 和 feed-forward 网络, 简化了网络设计。

2.2 架构变化对量化技术的影响

从 U-Net 到 DiT 的架构转变对量化技术提出了新的要求和挑战。

激活分布特性的变化: U-Net 中的卷积层具有相对规律的激活分布, 而 Transformer 中的 attention 机制产生的激活值分布更加复杂。研究发现, DiT 中存在突出通道 (salient channels), 即某些通道的激活值远大于其他通道, 这种不平衡分布增加了量化的难度。

时间维度的复杂性: DiT 在不同去噪时间步骤中的激活分布存在显著差异。在早期时间步骤中, 模型主要处理粗粒度的结构信息, 激活值相对较大; 在后期时间步骤中, 模型精细化细节特征, 激活值分布发生明显变化。这种时间变化特性要求量化方法具备动态适应能力。

注意力机制的量化挑战: Self-attention 中的 query、key、value 矩阵乘法对精度要求较高, 传统的激进量化方法容易破坏注意力权重的细微差别, 导致生成质量下降。

条件信息的处理: DiT 中的条件注入机制 (如 adaLN) 引入了额外的参数动态性, 这些运行时计算的归一化参数难以进行 offline 量化优化。

2.3 视频生成的额外复杂性

视频生成相比图像生成面临更加复杂的挑战, 这些挑战在量化过程中进一步放大。

时空建模复杂性: 视频 DiT 需要同时建模空间和时间维度的依赖关系, 对于分解的注意力机制 (spatial attention + temporal attention), 不同类型的注意力对量化精度的敏感性不同, 可能需要采用差异化的量化策略。

时间一致性要求: 视频生成对帧间一致性有严格要求, 即使微小的量化误差也可能导致时间维度上的不连贯性, 产生闪烁、抖动等视觉伪影。

内存和计算压力: 视频数据的序列长度使得激活值的内存占用呈线性增长, 同时计算复杂度随帧数和分辨率呈指数增长。这对量化技术的内存效率和计算效率提出了更高要求。

多模态信息融合: 现代视频生成模型通常需要处理文本、音频等多模态信息, 不同模态的信息具有不同的数值特性和精度要求, 需要协调的量化策略。

3 量化技术基础理论与方法

3.1 量化数学基础

量化本质上是一个信息压缩过程，其目标是在有限的比特预算下最大程度地保持原始信息。给定一个实数张量 $\mathbf{X} \in \mathbb{R}^{d_1 \times d_2 \times \dots \times d_n}$ ， b 位均匀量化可以表示为：

$$Q(\mathbf{X}) = \text{clamp} \left(\text{round} \left(\frac{\mathbf{X} - z}{s} \right), 0, 2^b - 1 \right) \quad (1)$$

其中 s 为缩放因子， z 为零点偏移， $\text{clamp}(\cdot, a, b)$ 将数值限制在区间 $[a, b]$ 内。反量化过程为：

$$\hat{\mathbf{X}} = s \cdot Q(\mathbf{X}) + z \quad (2)$$

量化误差可以分解为两个主要部分：

$$E = \|\mathbf{X} - \hat{\mathbf{X}}\|_F^2 = E_{\text{clamp}} + E_{\text{round}} \quad (3)$$

其中 E_{clamp} 为截断误差， E_{round} 为舍入误差。截断误差源于量化范围的限制，当张量中存在超出量化范围的异常值时产生；舍入误差源于连续值到离散值的映射过程，其大小与量化步长 s 密切相关。

3.2 传统量化方法的局限性

Min-Max 量化是最简单的量化方法，直接使用张量的极值确定量化范围：

$$s = \frac{\max(\mathbf{X}) - \min(\mathbf{X})}{2^b - 1}, \quad z = -\min(\mathbf{X})/s \quad (4)$$

这种方法虽然实现简单，但存在明显缺陷：对异常值极为敏感，少数极值会导致大部分正常值被压缩到很小的量化区间，严重影响量化精度。


3.3 生成模型量化的核心挑战

当前生成模型量化技术面临的核心挑战主要集中在三个方面。首先是极低比特量化的质量保持问题，当精度降至 4 比特时，传统方法往往导致严重质量退化。其次是视频生成的时间一致性维护挑战。量化误差在时间维度的累积容易导致帧间跳跃和闪烁效应，严重影响视频质量。第三个挑战是标定数据依赖和硬件适配性。传统方法需要大量标定数据统计激活分布，增加了部署复杂度。下文介绍的方法中将逐个给出解决的方案。

4 现有量化技术深入分析

4.1 通用量化方法的发展

4.1.1 SmoothQuant：平衡权重与激活量化



SmoothQuant[4] 是第一个系统性解决 Transformer 量化中通道不平衡问题的方法。其核心思想是通过引入通道级别的缩放因子来平衡权重和激活值的量化难度。在传统的量化方法中，激活值和权重往往存在显著的数值分布差异，某些通道的激活值可能具有极大的动态范围，而对应的权重值相对较小，SmoothQuant 通过数学变换巧妙地将通道上的异常值迁移到权重上，具体而言：给定线性层 $\mathbf{Y} = \mathbf{X}\mathbf{W}^T$ ，SmoothQuant 引入对角缩放矩阵 $\mathbf{S} = \text{diag}(s_1, s_2, \dots, s_d)$ ，将计算重写为：

$$\mathbf{Y} = (\mathbf{X}\mathbf{S}^{-1}) \cdot (\mathbf{S}\mathbf{W}^T) = \tilde{\mathbf{X}} \cdot \tilde{\mathbf{W}}^T \quad (5)$$

缩放因子的计算公式为：

$$s_j = \frac{\max(|\mathbf{X}_{:,j}|)^\alpha}{\max(|\mathbf{W}_{j,:}|)^{1-\alpha}} \quad (6)$$

其中 $\alpha \in [0, 1]$ 是平衡参数。当 $\alpha = 0$ 时，所有量化难度转移到权重；当 $\alpha = 1$ 时，保持原始分布；当 $\alpha = 0.5$ 时，实现最大程度的平衡。

4.1.2 QuaRot：基于旋转的量化优化

QuaRot[5] 提出了一种基于正交旋转的量化方法，通过重新分布激活值来改善量化效果。该方法着重于解决传统量化方法面临的激活值分布不均匀对量化的影响。与 SmoothQuant 不同的是，QuaRot 引入正交旋转矩阵 $\mathbf{Q}$ ，满足 $\mathbf{Q}\mathbf{Q}^T = \mathbf{I}$ ，将原始计算 $\mathbf{Y} = \mathbf{X}\mathbf{W}^T$ 重写为：

$$\mathbf{Y} = (\mathbf{X}\mathbf{Q})(\mathbf{Q}^T\mathbf{W}^T) = \tilde{\mathbf{X}}\tilde{\mathbf{W}}^T \quad (7)$$

正交旋转矩阵能够消除 outlier 的核心原理在于其重新分布数据的能力。具体而言，原始激活值中的 outlier 往往集中在少数几个通道中，这些极值严重影响量化范围的设定，导致大部分正常值的量化精度下降。通过正交变换，outlier 的能量被分散到多个通道中，从而降低了数据的不一致性 (incoherence)。根据不一致性处理理论，当数据组的




图 1: Quarot

最大值相对于平均幅度较小时，量化误差会显著降低。正交矩阵的保范性质确保了变换前后数据的总能量不变，同时其列向量的正交性保证了激活值在各通道间的均匀分布，使得量化后的误差分布更加平衡。

在具体实现上，QuaRot 选择 Hadamard 矩阵作为旋转矩阵，这一选择主要基于三个重要考虑：首先是计算效率，Hadamard 变换可以通过快速算法在 $O(d \log d)$ 时间内完成；其次，Hadamard 矩阵是理论上能够最大程度分散激活值的最优旋转矩阵；最后，Hadamard 变换只涉及加减运算，易于硬件实现。




图 2: SpinQuant

为了进一步减少推理时的计算开销，SpinQuant[6] 在 QuaRot 的基础上提出了离线合并旋转矩阵的策略。SpinQuant 通过学习得到的旋转矩阵可以在推理前预先与权重矩阵合并，即将 $\mathbf{Q}^T \mathbf{W}$ 作为新的权重存储，这样在推理时只需要对激活值进行旋转变换 $\mathbf{XQ}$ ，从而将旋转操作的计算复杂度减半。这种离线合并策略特别适用于权重可以预先处理的场景，能够在保持量化效果的同时显著降低推理延迟。

然而，在扩散模型中，由于自适应归一化层（adaptive normalization）的存在，旋转矩阵的应用面临着独特的挑战。运行时生成的归一化权重使得旋转矩阵无法与投影层

的权重进行离线整合，因此对激活值和权重都进行在线旋转会产生显著的运行时开销。这一限制使得在扩散 transformer 中应用旋转基方法需要更加谨慎的设计，以平衡量化效果与计算效率。

4.2 DiT 专用量化技术详解

4.2.1 PTQ4DiT: 开创性的 DiT 量化方法




图 3: PTQ4DiT

PTQ4DiT[7] 是第一个专门针对 Diffusion Transformers 设计的量化方法，深入分析了 DiT 量化的独特挑战并提出了针对性解决方案。该方法识别出 DiT 量化面临的两个核心挑战：首先是突出通道问题，即 DiT 中线性层的权重和激活都存在极值较大的通道，这些通道在量化时产生显著误差；其次是时间变化特性，激活值分布在不同去噪时间步骤中存在显著差异，静态量化参数难以适应这种变化。

针对突出通道问题，PTQ4DiT 提出了 Channel-wise Saliency Balancing (CSB) 方法。该方法基于一个重要观察：权重和激活的突出通道通常不重合，存在天然的互补性。利用这一特性，CSB 设计了 Saliency Balancing Matrices 来重新分布通道间的突出性，将激活和权重中的极值进行互补性重分配。具体而言，CSB 通过对角矩阵 $\mathbf{B}_X$ 和 $\mathbf{B}_W$ 对激活和权重进行变换： $\tilde{\mathbf{X}} = \mathbf{X}\mathbf{B}_X$ ， $\tilde{\mathbf{W}} = \mathbf{B}_W\mathbf{W}$ ，其中对角元素计算为 $(\mathbf{B}_X)_{ii} = \frac{\sqrt{s(X_i) \cdot s(W_i)}}{s(X_i)}$ ， $(\mathbf{B}_W)_{ii} = \frac{\sqrt{s(X_i) \cdot s(W_i)}}{s(W_i)}$ ， $s(\cdot)$ 表示通道的突出性度量，定义为通道元素的最大绝对值。这种平衡机制能够使得每个通道的突出性趋于一致，从而降低整体的量化难度。

为了处理激活值在不同时间步骤中的分布变化，PTQ4DiT 进一步提出了 Spearman's ρ -guided Saliency Calibration (SSC) 方法。SSC 的核心思想是根据不同时间步骤中权重和激活突出性的相关程度来动态调整校准权重，相关性越低的时间步骤表明互补性越强，应该给予更大的权重。SSC 通过加权聚合多个时间步骤的激活突出性来计算时间校准的突出性： $s_\rho(\mathbf{X}^{(1:T)}) = \sum_{t=1}^T \eta_t \cdot s(\mathbf{X}^{(t)})$ ，其中权重因子 $\eta_t = \frac{\exp[-\rho(s(\mathbf{X}^{(t)}), s(\mathbf{W}))]}{\sum_{\tau=1}^T \exp[-\rho(s(\mathbf{X}^{(\tau)}), s(\mathbf{W}))]}$

基于 Spearman 相关系数的负指数计算得出。这种设计确保了互补性更强的时间步骤获得更大的权重，从而优化整体的平衡效果。

4.2.2 SVDQuant: 极低比特量化的突破




图 4: SVDQuant

SVDQuant[8] 针对 W4A4 这一极具挑战性的量化设置，提出了基于低秩分解的创新解决方案。该方法的核心洞察在于发现传统的平衡方法（如 smoothing）虽然能够将激活值中的异常值转移到权重中，但这种转移会使得权重的量化变得更加困难，从而限制了整体的量化效果。为了突破这一瓶颈，SVDQuant 提出引入 16 比特的低秩分支来专门处理这些被转移的异常值，使得主分支能够在 4 比特精度下正常工作。具体而言，该方法首先通过 smoothing 将激活值中的异常值迁移到权重中，然后使用奇异值分解 (SVD) 将权重矩阵分解为低秩分支和残差两部分，最后对低秩分支保持 16 比特精度，仅对残差部分进行 4 比特量化。

SVDQuant 的设计基于严格的数学理论分析。对于线性层 $\mathbf{Y} = \mathbf{X}\mathbf{W}$ ，量化误差可以分解为权重和激活两部分的贡献，该方法证明了量化误差的上界：

$$E(\mathbf{X}, \mathbf{W}) \leq \|\mathbf{X}\|_F \|\mathbf{W} - Q(\mathbf{W})\|_F + \|\mathbf{X} - Q(\mathbf{X})\|_F (\|\mathbf{W}\|_F + \|\mathbf{W} - Q(\mathbf{W})\|_F) \quad (8)$$

基于这一理论框架，SVDQuant 的关键是最小化残差矩阵 $\mathbf{R} = \hat{\mathbf{W}} - \mathbf{L}_1\mathbf{L}_2$ 的 Frobenius 范数，其中 $\hat{\mathbf{W}}$ 是经过 smoothing 处理的权重矩阵。通过将权重矩阵中的主要奇异值分离到低秩分支中，残差矩阵的幅度和异常值程度都显著降低，从而使得 4 比特量化成为可能。

在具体的 SVD 分解策略中，给定权重矩阵 $\hat{\mathbf{W}}$ 的奇异值分解 $\hat{\mathbf{W}} = \mathbf{U}\Sigma\mathbf{V}^T$ ，该方法选择前 r 个最大的奇异值构建低秩分支：

$$\mathbf{L}_1 = \mathbf{U}_{:,1:r}, \quad \mathbf{L}_2 = \Sigma_{1:r,1:r} \mathbf{V}_{:,1:r}^T \quad (9)$$

其中 r 是低秩分支的秩。根据 Eckart-Young-Mirsky 定理，这种分解能够最小化残差矩阵的 Frobenius 范数：

$$\|\mathbf{R}\|_F = \sqrt{\sum_{i=r+1}^{\min(m,n)} \sigma_i^2} \quad (10)$$

实验观察表明，经过 smoothing 处理的权重矩阵通常具有急剧衰减的奇异值分布，前几个奇异值占据了绝大部分能量，这使得低秩分解特别有效。

为了解决低秩分支可能带来的额外计算开销问题，SVDQuant 设计了专门的推理引擎 Nunchaku。该引擎通过 kernel fusion 技术，将低秩分支的 down projection 与量化操作融合，将 up projection 与 4 比特计算融合，从而消除了额外的内存访问开销。实验结果显示，在 12B 参数的 FLUX.1 模型上，SVDQuant 实现了 3.5 倍的内存压缩和 3.0 倍的推理加速，LPIPS 仅为 0.254，甚至优于传统 W4A16 基线的 0.272。此外，由于低秩分支的设计天然兼容 LoRA 等低秩适配器，该方法能够支持无缝集成现有的微调模块，无需重新量化。

4.3 视频生成量化的专门技术

4.3.1 ViDiT-Q: 统一的图像视频量化框架




图 5: ViDiT-Q

ViDiT-Q[9] 针对 DiT 模型的多维度变化特性，提出了更加全面和系统的量化解决方案。该方法通过深入分析发现，DiT 中存在四种关键的数据变化模式：token-wise 变化体现在不同空间位置的 token 具有不同的激活分布；condition-wise 变化表现为条件生成和无条件生成的激活分布差异；timestep-wise 变化反映了不同时间步骤的激活分布动态变化；以及 channel-wise 变化显示的通道间激活值分布不平衡性。这些多维度的变化使得传统的静态、粗粒度量化方法难以有效处理 DiT 模型的复杂分布特性。

为了处理这些多维度变化，ViDiT-Q 采用了细粒度的动态量化策略。在权重量化方面，该方法采用 channel-wise 量化，为每个输出通道分配独立的量化参数；在激活量化方面，采用 token-wise 量化，为每个 token 使用独立的量化参数。更重要的是，所有量化参数都在线动态计算，以适应不同时间步骤和条件下的分布变化。动态量化参数的计

算公式为：

$$s_t^{(i)} = \frac{\max(|\mathbf{X}_t^{(i)}|) - \min(|\mathbf{X}_t^{(i)}|)}{2^b - 1} \quad (11)$$

其中 $\mathbf{X}_t^{(i)}$ 表示时间步骤 t 下第 i 个 token 的激活值。这种动态计算方式确保了量化参数能够准确反映当前的数据分布特征。

针对 DiT 中时变的通道不平衡问题，ViDiT-Q 创新性地结合了 scaling 和 rotation 方法的优势，提出了静态-动态通道平衡技术。该方法将时变通道不平衡现象分解为两个组成部分：源自预训练权重的”静态”初始分布不平衡和由时间嵌入引入的”动态”变化。基于这一分析，方法首先使用静态缩放处理初始的通道不平衡，然后应用动态旋转处理时变分布，变换公式为：

$$\tilde{\mathbf{X}} = \mathbf{X} \mathbf{S}_{\text{static}} \mathbf{Q}_{\text{dynamic}} \quad (12)$$

其中 $\mathbf{S}_{\text{static}}$ 是基于预训练权重统计的静态缩放矩阵， $\mathbf{Q}_{\text{dynamic}}$ 是基于当前激活的动态旋转矩阵。

ViDiT-Q 进一步观察到量化对生成质量的不同方面具有差异化影响，据此提出了度量解耦的混合精度分配策略。该方法发现交叉注意力层主要影响文本-图像对齐，因此分配较高精度；自注意力层主要影响视觉质量，采用中等精度；前馈网络层主要影响局部特征，可以使用较低精度。为了量化这种影响差异，方法基于层级敏感性分析进行精度分配：

$$\text{Sensitivity}(l) = \frac{\sum_m w_m \cdot \Delta \text{Metric}_m(l)}{\sum_m w_m} \quad (13)$$

其中 $\Delta \text{Metric}_m(l)$ 表示量化层 l 对度量 m 的影响， w_m 为度量权重。这种解耦策略能够在保持生成质量的同时最大化量化效率。

4.3.2 DVD-Quant：免标定数据的视频量化




图 6: DVD-Quant

DVD-Quant[10] 专注解决视频量化中的标定数据依赖问题，这在实际部署中具有重要意义。传统的视频 DiT 量化方法通常需要处理数百到数千帧的标定数据来收集激活统计信息，这不仅增加了巨大的计算负担，还在实际部署中带来了技术门槛。DVD-Quant 通过系统分析发现，DiT 权重表现出高斯分布特性，激活尺度在去噪时间步之间存在显著变化，且潜在特征在不同时间步之间存在变化规律，这些观察为设计免标定的量化方法提供了理论基础。

针对 DiT 权重的高斯分布特性，DVD-Quant 提出了 Progressive Bounded Quantization (PBQ) 方法。该方法摒弃了传统固定范围量化的做法，转而采用迭代边界收紧策略来动态适应权重分布。PBQ 从初始边界 $\{\alpha_0 = W_{\min}, \beta_0 = W_{\max}\}$ 开始，通过步长 Δ 逐步收紧量化范围： $\alpha_t = \alpha_{t-1} + \Delta$, $\beta_t = \beta_{t-1} - \Delta$ ，并在每次迭代中计算重构误差 $\epsilon_t = \|Q(\mathbf{W}) - \mathbf{W}\|_2^2$ ，最终选择误差最小的边界作为最优量化范围。这种自适应策略能够自动适应不同层的权重分布特性，避免了固定范围量化中异常值占用过多量化区间的问题，同时无需人工调参，算法能够自动确定最优边界。

为了解决激活量化中的时间步依赖和异常值问题，DVD-Quant 设计了 Auto-scaling Rotated Quantization (ARQ) 方法。该方法创新性地结合了 Hadamard 旋转和在线缩放的优势，首先通过 Hadamard 矩阵 $\mathbf{H}$ 对激活值进行旋转来分散异常值，然后应用在线计算的缩放因子来处理通道间的不平衡：

$$\hat{\mathbf{X}} = Q(\mathbf{X}\mathbf{H}\mathbf{\Lambda}^{-1}), \quad \hat{\mathbf{W}} = \text{PBQ}(\mathbf{W}\mathbf{H}) \quad (14)$$

其中 $\mathbf{\Lambda} = \text{diag}(s_1, \dots, s_d)$, $s_j = \|\tilde{\mathbf{X}}_j\|_\infty$ 。ARQ 的关键优势在于其在线缩放机制的计算复杂度仅为 $O(d)$ ，相比需要处理 n 个样本、 d 个通道、 k 个时间步的标定过程的 $O(ndk)$ 复杂度有显著优势。同时，Hadamard 旋转通过快速变换有效分散了激活值中的异常值，而免标定设计大大简化了部署流程。

考虑到视频生成过程中不同时间步的重要性差异，DVD-Quant 进一步提出了 δ -Guided Bit Switching (δ -GBS) 方法。该方法基于特征演化监控来动态分配比特宽度，通过持续跟踪归一化的特征变化度量来判断当前阶段的重要性：

$$L_1(\mathbf{F}, t) = \frac{\|\mathbf{F}_t - \mathbf{F}_{t+1}\|_1}{\|\mathbf{F}_{t+1}\|_1} \quad (15)$$

当累积的特征变化低于阈值 δ 时，表明当前处于稳定的细化阶段，可以使用较低的比特宽度 b_{low} ；当累积变化超过阈值时，表明正在发生重要的结构变化，需要切换到较高的比特宽度 b_{high} ：

$$B_t^{(i)} = \begin{cases} b_{\text{low}}, & \text{if } \sum_{t_p}^{t_i-1} L_1(\mathbf{F}, t) < \delta \\ b_{\text{high}}, & \text{if } \sum_{t_p}^{t_i-1} L_1(\mathbf{F}, t) \geq \delta \end{cases} \quad (16)$$

这种自适应比特切换机制能够根据输入特征的动态特性进行精度分配，避免了静态混合精度策略可能导致的资源浪费。

5 技术总结与发展

生成模型量化技术的未来发展将朝着三个主要方向演进。端到端优化将成为技术发展的核心趋势,不再局限于单一算法层面的改进,而是将量化与剪枝、蒸馏、架构搜索等技术进行联合设计。这种系统级优化方法可表述为多目标优化问题: $\min_{\theta, q, p} \lambda_1 \mathcal{L}_{\text{quality}}(\theta, q, p) + \lambda_2 \mathcal{L}_{\text{efficiency}}(\theta, q, p) + \lambda_3 \mathcal{L}_{\text{memory}}(\theta, q, p)$, 其中 θ 、 q 、 p 分别表示模型参数、量化策略和剪枝策略。

智能化量化技术将利用机器学习方法自动优化量化配置。神经架构搜索 (NAS) 可以自动探索最优的比特宽度分配和量化方法组合,强化学习则能够根据生成质量反馈智能调整量化策略。元学习技术的引入将使量化方法具备快速适应新模型和新任务的能力,通过 $\phi^* = \arg \min_{\phi} \mathbb{E}_{\mathcal{T} \sim p(\mathcal{T})} \mathcal{L}_{\mathcal{T}}(\text{QuickAdapt}(\phi, \mathcal{D}_{\mathcal{T}}^{\text{support}}), \mathcal{D}_{\mathcal{T}}^{\text{query}})$ 实现跨任务的量化知识迁移。

硬件协同设计将成为突破性能瓶颈的关键。未来的量化方法需要深度结合目标硬件特性,包括充分利用 Tensor Core、AI 加速器等专用计算单元,优化内存层次结构的数据访问模式。随着 NVIDIA Blackwell 等新一代硬件对 FP4 等格式的原生支持,预期将出现专门针对新硬件特性设计的量化方法,实现更大的性能突破。

应用前景方面,量化技术将推动生成模型在边缘设备的普及部署。预计在未来 3-5 年内,10B 级别的生成模型将能够在主流移动 GPU 上实现实时推理。同时,极低比特量化的成熟将使视频生成模型达到实时响应水平 (<33ms per frame),为虚拟主播、实时视频编辑等应用场景提供技术基础。

参考文献

- [1] OpenAI. Sora: Creating video from text. *online*, 2024. Accessed: 2024-02-15.
- [2] Weijie Kong, Qi Tian, Zijian Zhang, Rox Min, Zuozhuo Dai, Jin Zhou, Jiangfeng Xiong, Xin Li, Bo Wu, Jianwei Zhang, et al. Hunyuanvideo: A systematic framework for large video generative models. *arXiv preprint arXiv:2412.03603*, 2024.
- [3] Zhimin Li, Jianwei Zhang, Qin Lin, Jiangfeng Xiong, Yanxin Long, Xinchu Deng, Yingfang Zhang, Xingchao Liu, Minbin Huang, Zedong Xiao, et al. Hunyuan-dit: A powerful multi-resolution diffusion transformer with fine-grained chinese understanding. *arXiv preprint arXiv:2405.08748*, 2024.
- [4] Guangxuan Xiao, Ji Lin, Mickael Seznec, Hao Wu, Julien Demouth, and Song Han. SmoothQuant: Accurate and efficient post-training quantization for large language models. In *ICML*, 2023.

-
- [5] Saleh Ashkboos, Amirkeivan Mohtashami, Maximilian Croci, Bo Li, Pashmina Cameron, Martin Jaggi, Dan Alistarh, Torsten Hoefer, and James Hensman. Quarot: Outlier-free 4-bit inference in rotated llms. In *NeurIPS*, 2024.
 - [6] Zechun Liu, Changsheng Zhao, Igor Fedorov, Bilge Soran, Dhruv Choudhary, Raghuraman Krishnamoorthi, Vikas Chandra, Yuandong Tian, and Tijmen Blankevoort. Spinqant: Llm quantization with learned rotations. In *ICLR*, 2025.
 - [7] Junyi Wu, Haoxuan Wang, Yuzhang Shang, Mubarak Shah, and Yan Yan. Ptq4dit: Post-training quantization for diffusion transformers. In *NeurIPS*, 2024.
 - [8] Muyang Li*, Yujun Lin*, Zhekai Zhang*, Tianle Cai, Xiuyu Li, Junxian Guo, Enze Xie, Chenlin Meng, Jun-Yan Zhu, and Song Han. Svdquant: Absorbing outliers by low-rank components for 4-bit diffusion models. In *ICLR*, 2025.
 - [9] Tianchen Zhao, Tongcheng Fang, Enshu Liu, Wan Rui, Widyadewi Soedarmadji, Shiyao Li, Zinan Lin, Guohao Dai, Shengen Yan, Huazhong Yang, Xuefei Ning, and Yu Wang. Vedit-q: Efficient and accurate quantization of diffusion transformers for image and video generation. *ICLR*, 2025.
 - [10] Zhiteng Li, Hanxuan Li, Junyi Wu, Kai Liu, Linghe Kong, Guihai Chen, Yulun Zhang, and Xiaokang Yang. Dvd-quant: Data-free video diffusion transformers quantization. *arXiv preprint arXiv:2505.18663*, 2025.